Языковые модели и системы на их основе

Обучение, fine-tuning, LoRA, RAG и агенты

Задача языкового моделирования

Контекст задаёт распределение следующего токена

Вероятность текста складывается из условных вероятностей

Токен может быть словом, частью слова или знаком

$$P(x_1, \ldots, xT) = \prod_t P(x_t \mid x<t)$$

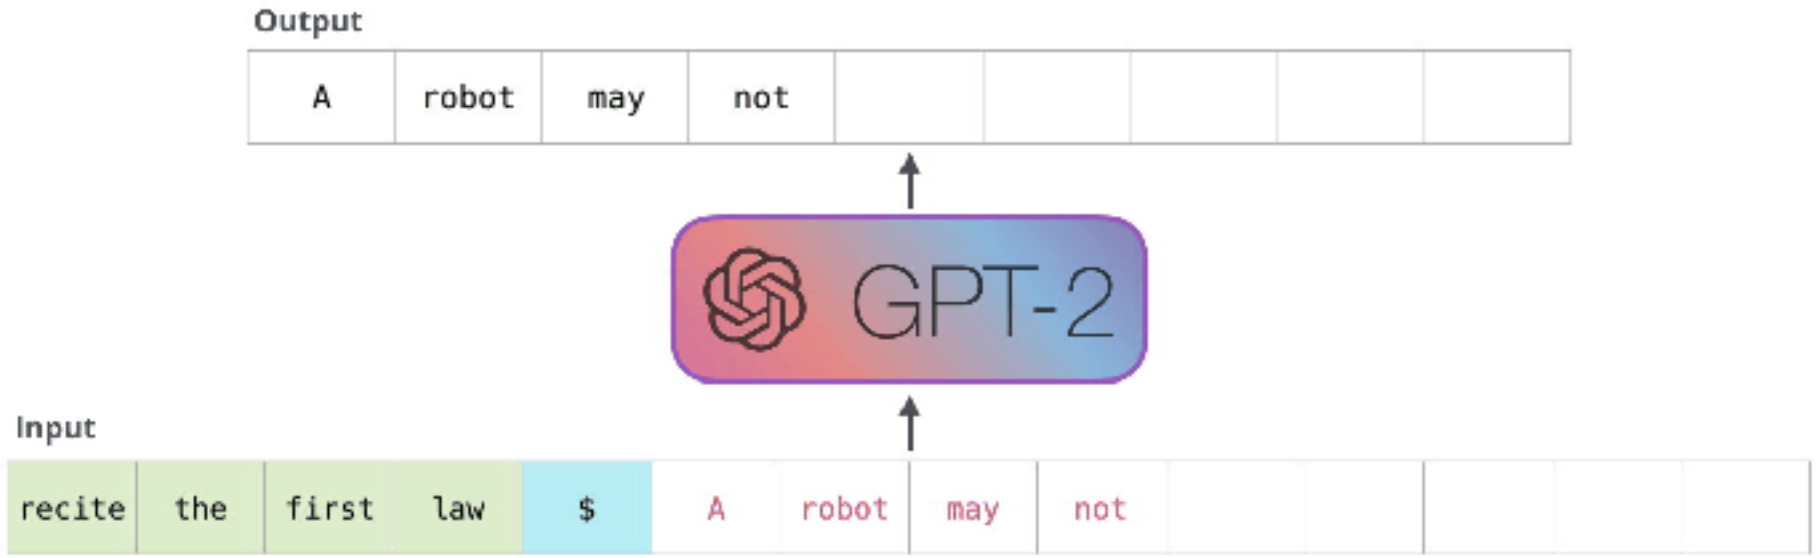
Текст как обучающий пример

Токенизация превращает строку в последовательность ID

Известный префикс	Целевой токен
<начало>	Нужен
<начало> Нужен	лёгкий
<начало> Нужен лёгкий	ноутбук

Условная токенизация для иллюстрации сдвига

Авторегрессионная генерация

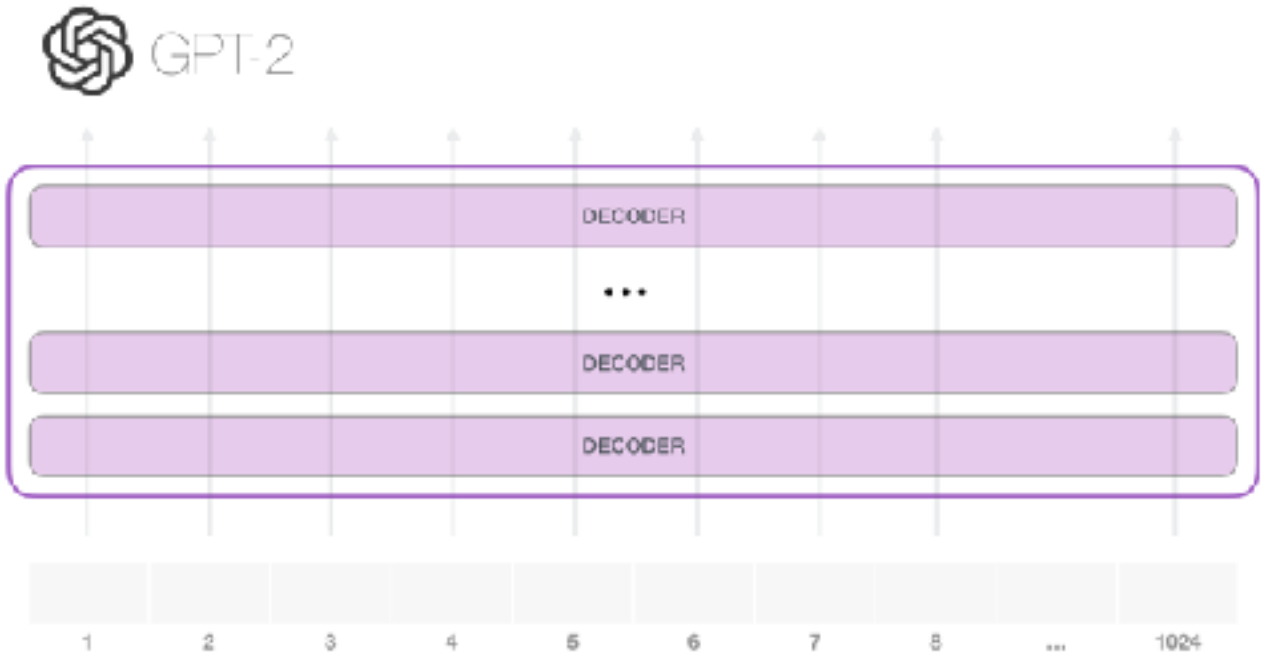


Выбранный токен дописывается к контексту

Greedy выбирает максимум, sampling делает выборку

Temperature меняет концентрацию распределения

Что представляет собой LLM



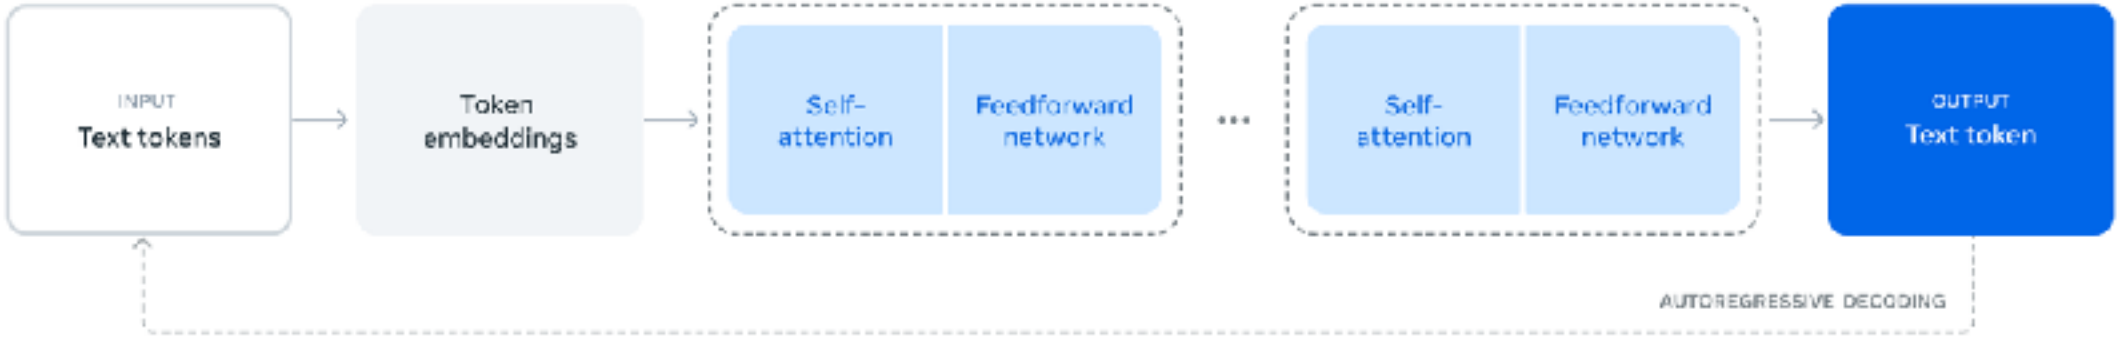
Архитектура задаёт вычисления

Веса хранят обученные параметры

Токенизатор кодирует текст

Приложение добавляет поиск и инструменты

Путь токена через Transformer



Embeddings и позиционная информация задают вход

Attention связывает позиции, MLP преобразует представления

Выходной слой формирует logits по словарю

Разные задачи как продолжение текста

Инструкция задаёт требуемое преобразование

Инструкция	Ожидаемый результат
Кратко перескажи описание	Понятный абзац
Извлеки объём памяти	{"ram_gb": 16}
Объясни характеристики новичку	Ответ без лишних терминов

Веса, контекст и внешние данные

Веса: усвоенные при обучении закономерности

Где информация	Как обновить
Параметры модели	Обучение
Контекст запроса	Изменить входные сообщения
Внешняя система	Обновить источник и получить данные

Этапы обучения LLM

Pretraining формирует базовую модель

Этап	Обучающий сигнал
Pretraining	Следующий токен исходного текста
SFT	Токены эталонного ответа
Preference learning	Сравнение ответов
RL с наградой	Оценка сгенерированного решения

Данные для pretraining

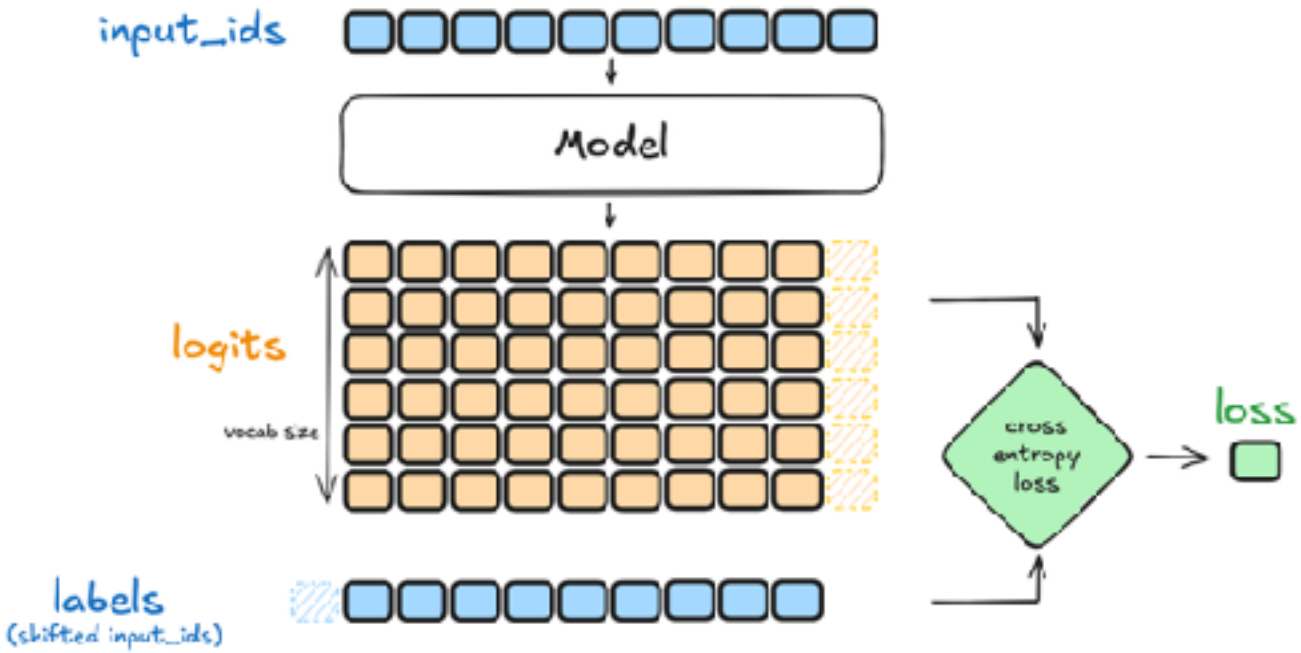
Источники и их смесь определяют обучающий опыт

Очистка и дедупликация уменьшают шум и повторы

Отложенные тесты защищают от утечки оценки

Почему миллион почти одинаковых документов может быть хуже меньшего, но разнообразного корпуса?

Один шаг pretraining



$L = -\text{mean}_t \log P\theta(x_t \mid x<t)$

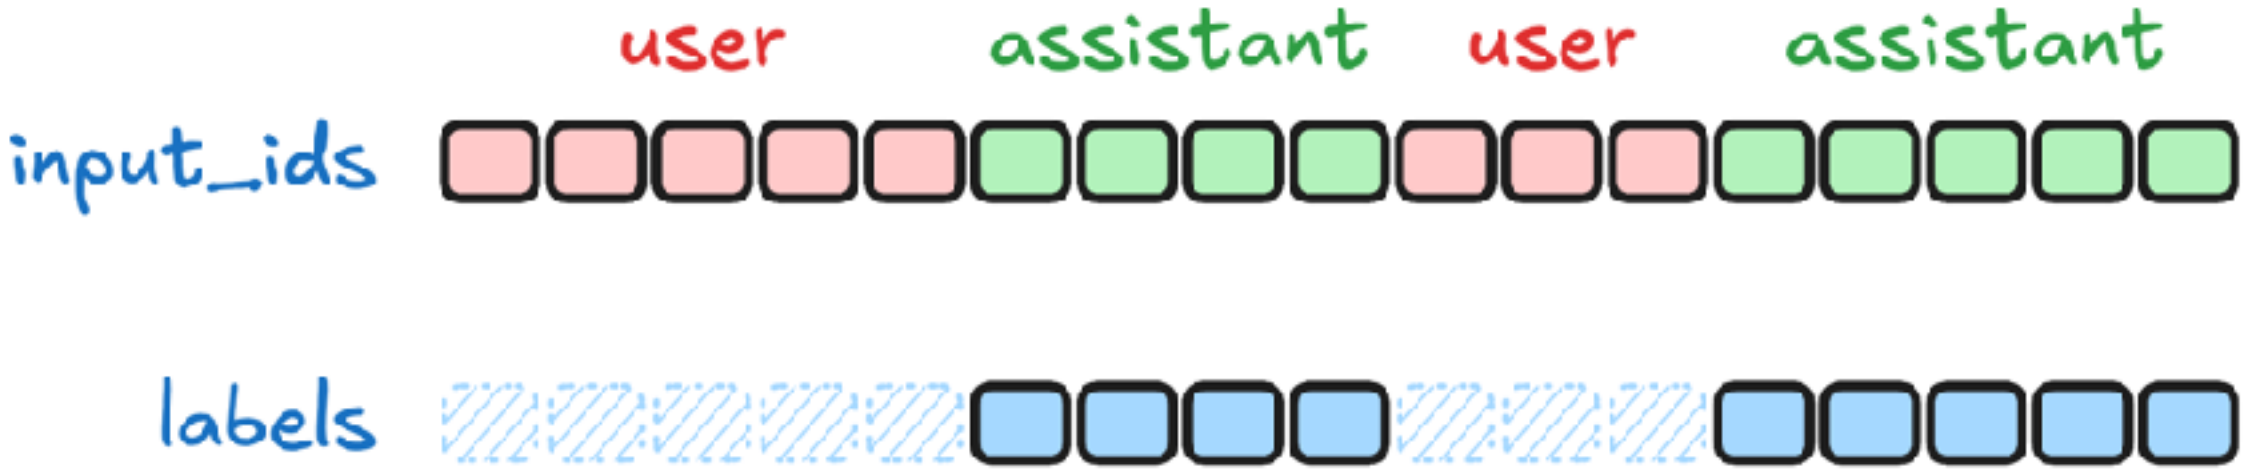
Forward вычисляет предсказания, оптимизатор обновляет веса

Base model и диалоговый ассистент

Base model умеет продолжать тексты разных типов

Одинаковый запрос	Условное продолжение
Base model	«Помоги выбрать телефон…» Продолжает список запросов
Instruction model	«Какой бюджет и какие программы вы используете?»

SFT и маска ответа



Обучающий пример содержит запрос и эталонный ответ

Chat template кодирует роли и границы сообщений

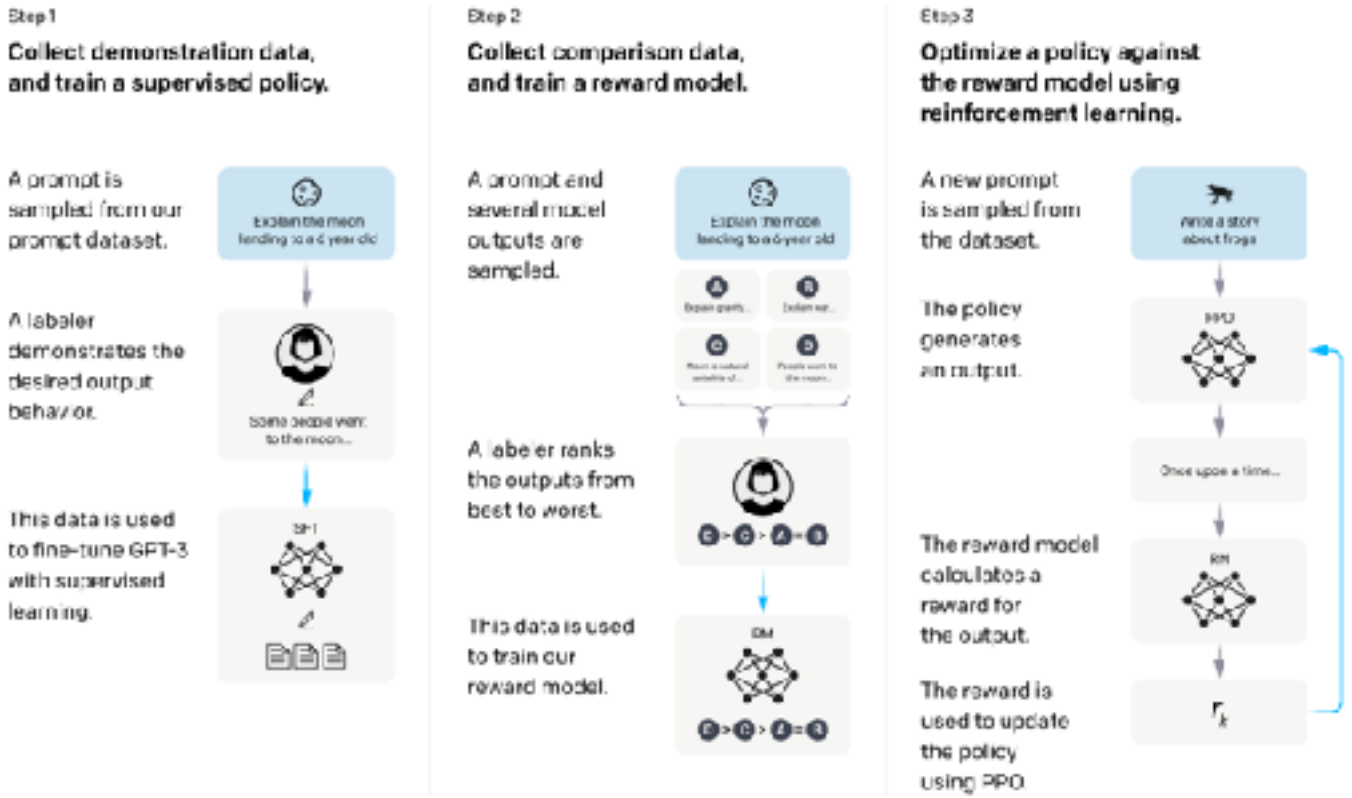
Loss можно считать только на ответах ассистента

Демонстрации и предпочтения

SFT показывает один желаемый ответ

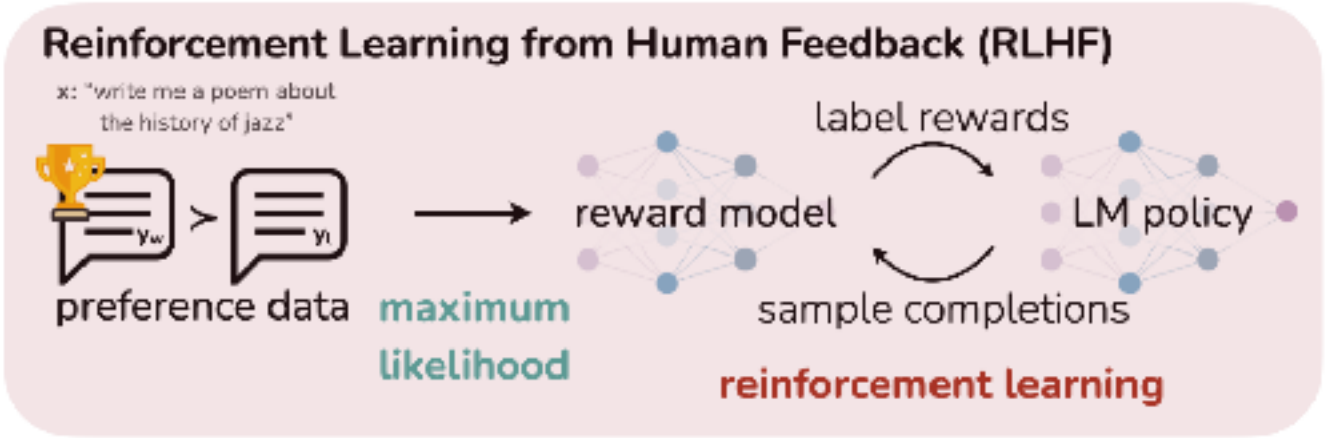
Ответ A	Ответ B
«Да, идеально для любого монтажа»	«Какая программа и разрешение видео?»
Уверенное обещание без достаточных данных	Уточнение перед рекомендацией

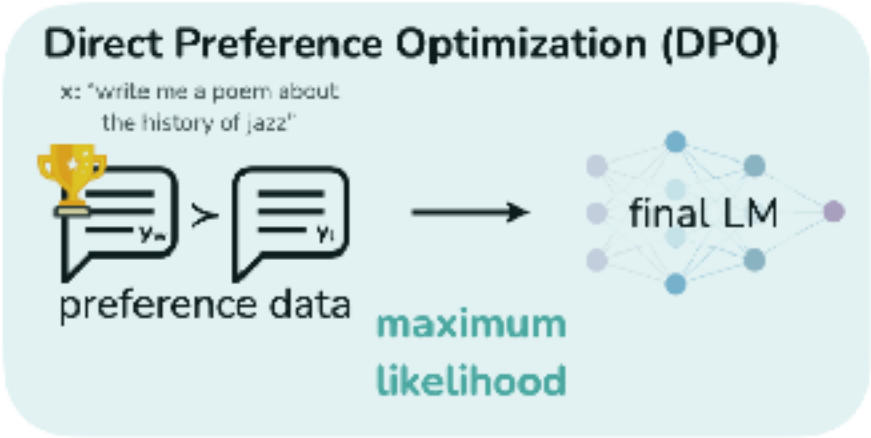
RLHF с моделью награды



Сравнения людей обучают оценщик, оценщик обучает policy

Direct Preference Optimization



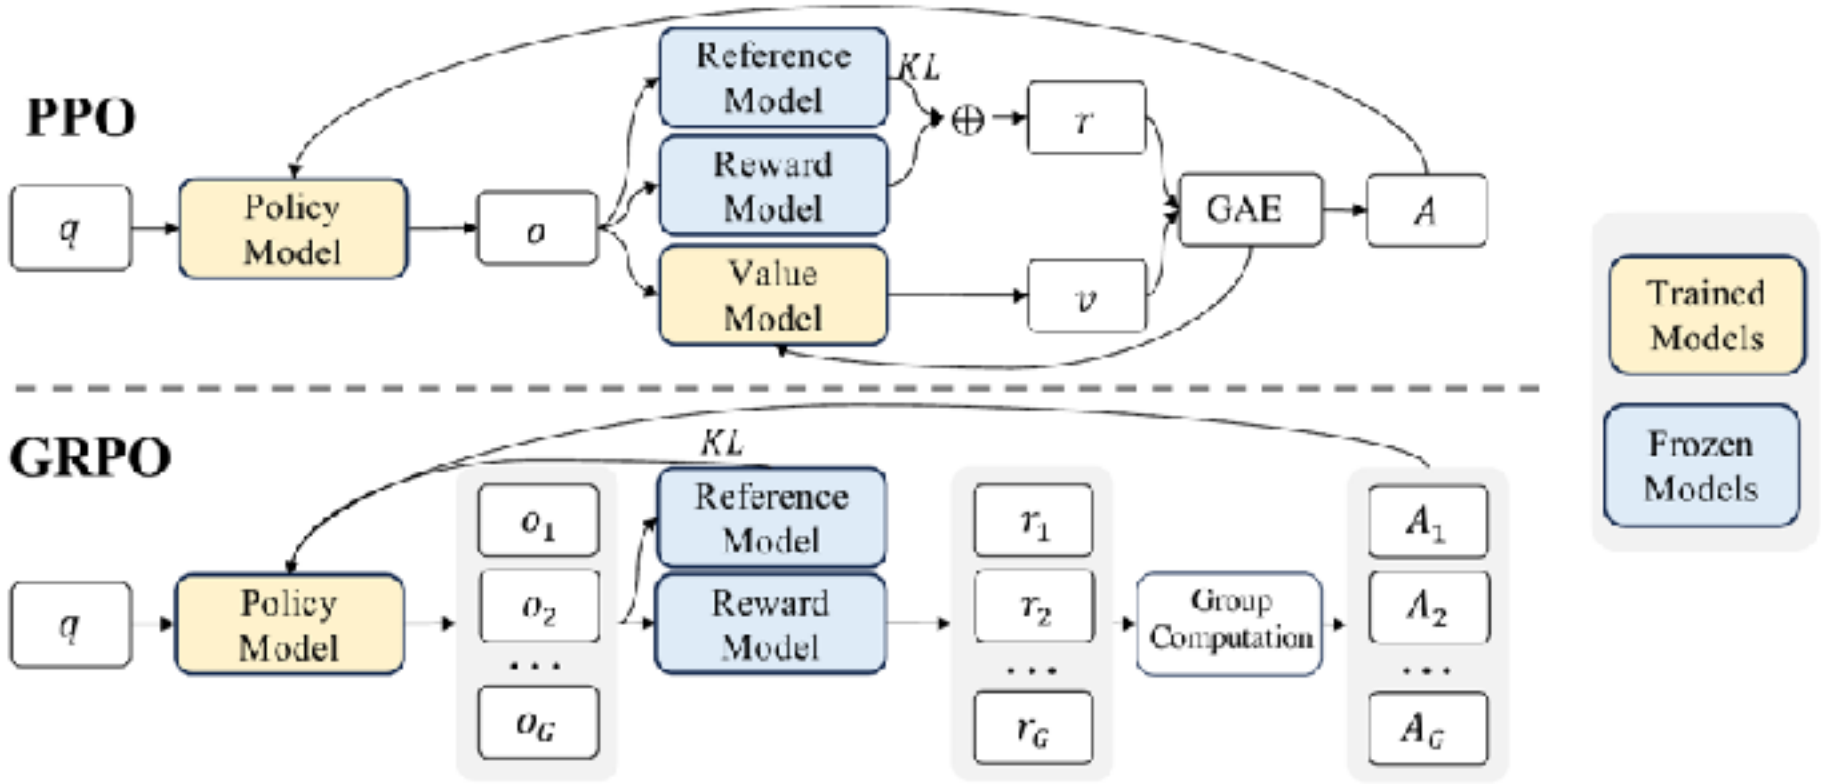


Запрос, выбранный ответ и отвергнутый ответ

Специальный loss использует относительные вероятности

В стандартном DPO не нужна отдельная reward model

Проверяемая награда и оценка модели



Источник награды и алгоритм оптимизации выбирают отдельно

Transfer learning и своя задача

Готовые веса дают исходные языковые способности

Наши данные	Возможный подход
Большой корпус технических текстов	Continued pretraining
Примеры консультаций	Instruction fine-tuning
Пары ответов с предпочтениями	Preference optimization

Когда полезен fine-tuning

Повторяющаяся задача и измеримый критерий качества

Устойчивый формат, стиль или специализация

Качественные примеры нужного поведения

Актуальные факты удобно получать из внешних источников

Помощник пишет неправильный JSON и называет вчерашнюю цену. Достаточно ли одной причины «нужно дообучить»?

Датасет для fine-tuning

Реальные запросы и проверенные ответы

Роль	Учебный пример
User	Нужен ноутбук для поездок и таблиц
Assistant	Какой бюджет и допустимый вес?
Проверка	Ответ уточняет недостающие ограничения

Цикл fine-tuning и проверки

Фиксируем baseline и независимый тест

Обучаем модель и выбираем checkpoint по validation

Проверяем целевое качество и регрессии

Разбираем ошибки и улучшаем данные

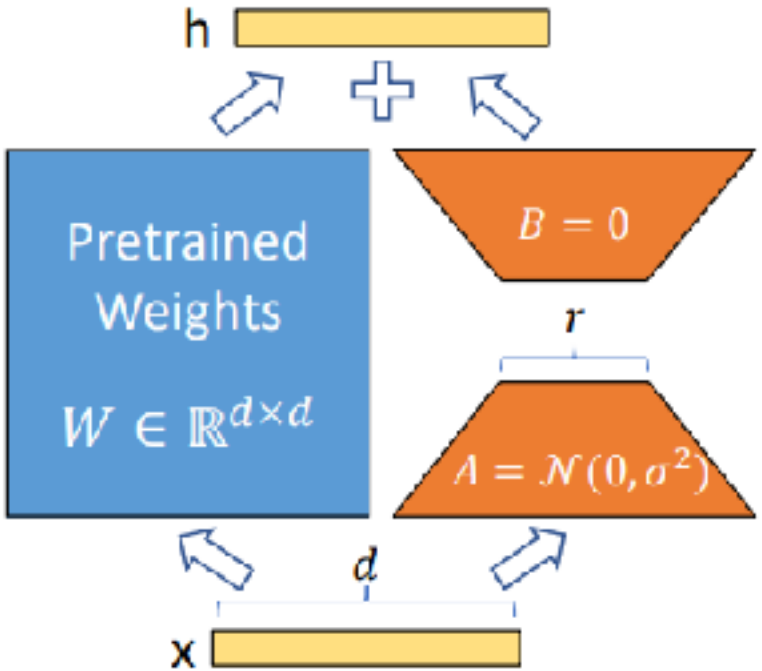
Training loss падает, а качество на новых запросах ухудшается. Какое объяснение проверим первым?

Память при полном fine-tuning

Память занимают веса, градиенты и состояние оптимизатора

Компонент	Условный mixed precision Adam
Веса bf16 + градиенты bf16	2 + 2 байта на параметр
Master fp32 + моменты fp32	4 + 8 байт на параметр
Активации и буферы	Зависят от конфигурации

LoRA: обучаемая поправка к весам



Базовая матрица W_0 остаётся замороженной

Обучается дополнительная поправка ΔW

LoRA ограничивает ранг этой поправки

$$W = W_0 + \Delta W$$

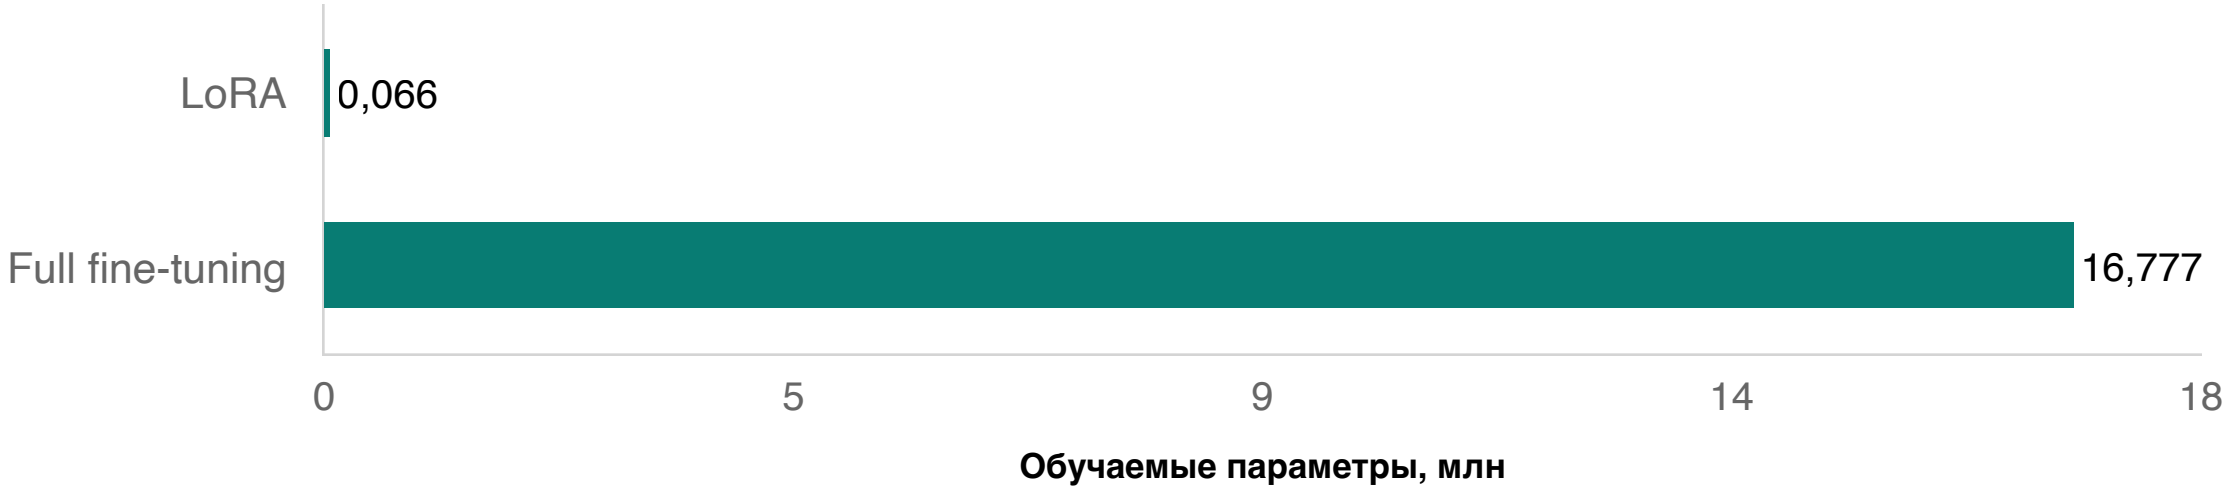
Размерности низкоранговой поправки

Операция	Размерность результата
x	d_in
Ax	r
B(Ax)	d_out

A: r × d_in B: d_out × r
ΔW = BA: d_out × d_in

LoRA: пример экономии параметров

Одна матрица 4096 × 4096, ранг адаптера r = 8



16 777 216 / 65 536 = 256 раз

Сравнение параметров, а не всей памяти или времени обучения

Forward и обучение LoRA

Основная ветка заморожена

Оптимизатор обновляет A и B

Масштаб α/r регулирует вклад поправки

$$y = W_0 x + (\alpha/r)\, B(Ax)$$

Ранг и места подключения LoRA

r задаёт ёмкость и размер адаптера

Настройка	Что меняет
Ранг r	Число параметров и ёмкость
Target modules	Места адаптации
α, learning rate, dropout	Динамику и устойчивость обучения

Адаптеры, объединение весов и QLoRA

База может быть общей для нескольких адаптеров

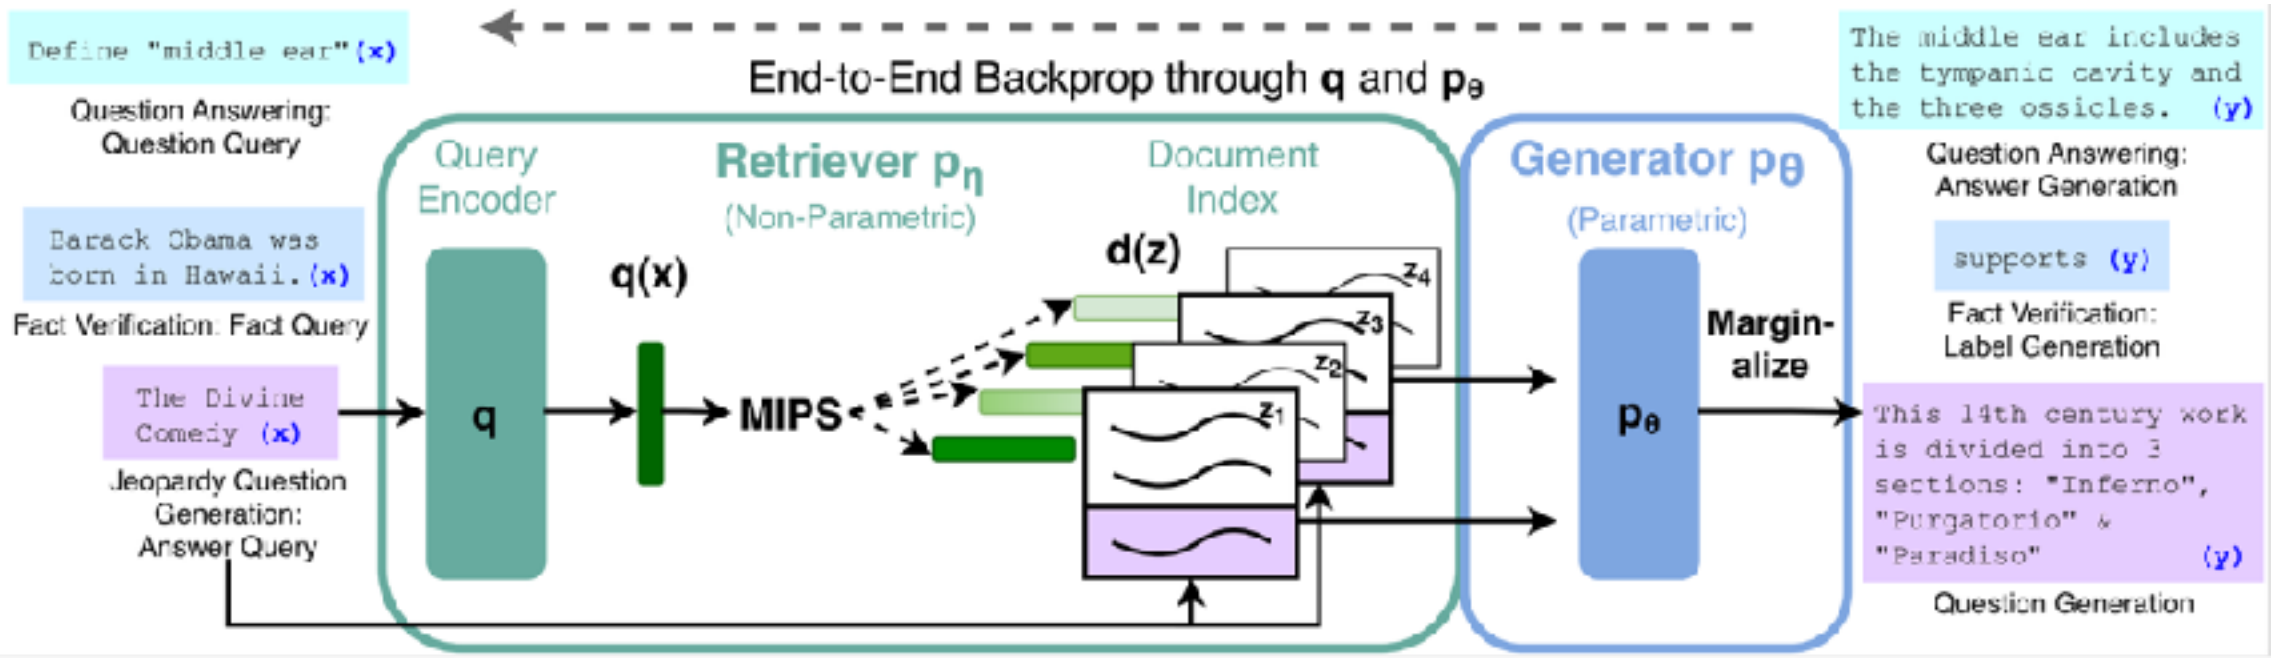
Поправку можно объединить с совместимыми весами

QLoRA сочетает LoRA с квантованной базой

Качество проверяется вместе с активным адаптером

Если исходные веса не изменились, может ли модель с включённой LoRA стать хуже на другой задаче?

RAG и внешние знания

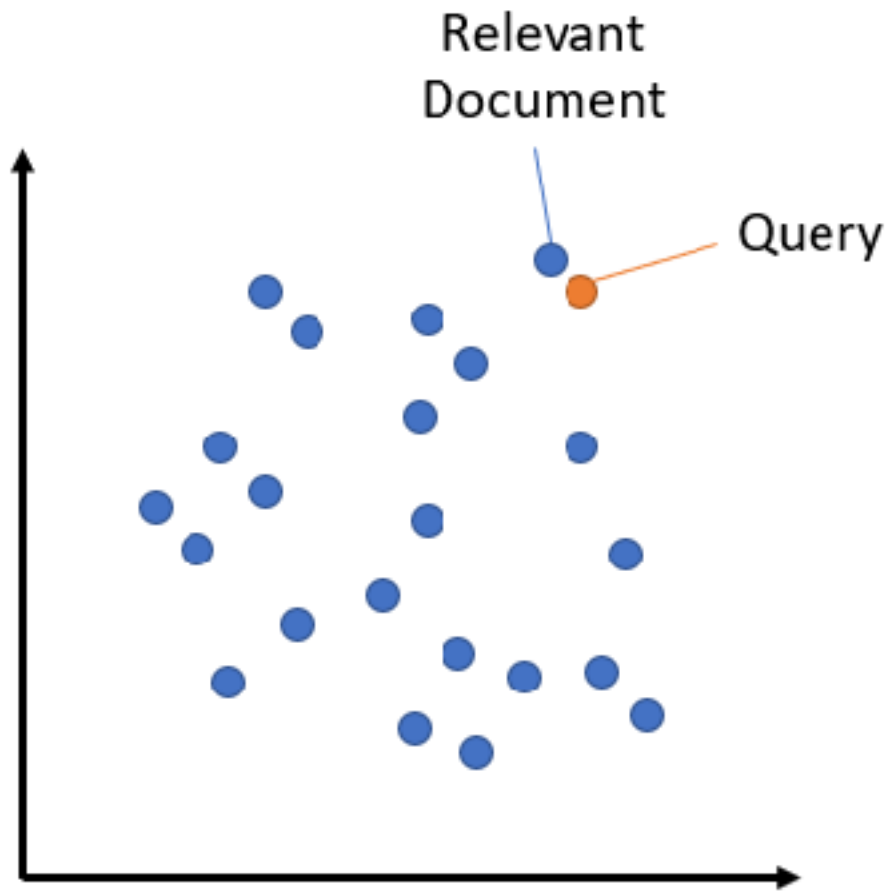


Запрос запускает поиск по внешним источникам

Найденные фрагменты добавляются в контекст

Модель формирует ответ на основе полученных сведений

Подготовка поискового индекса



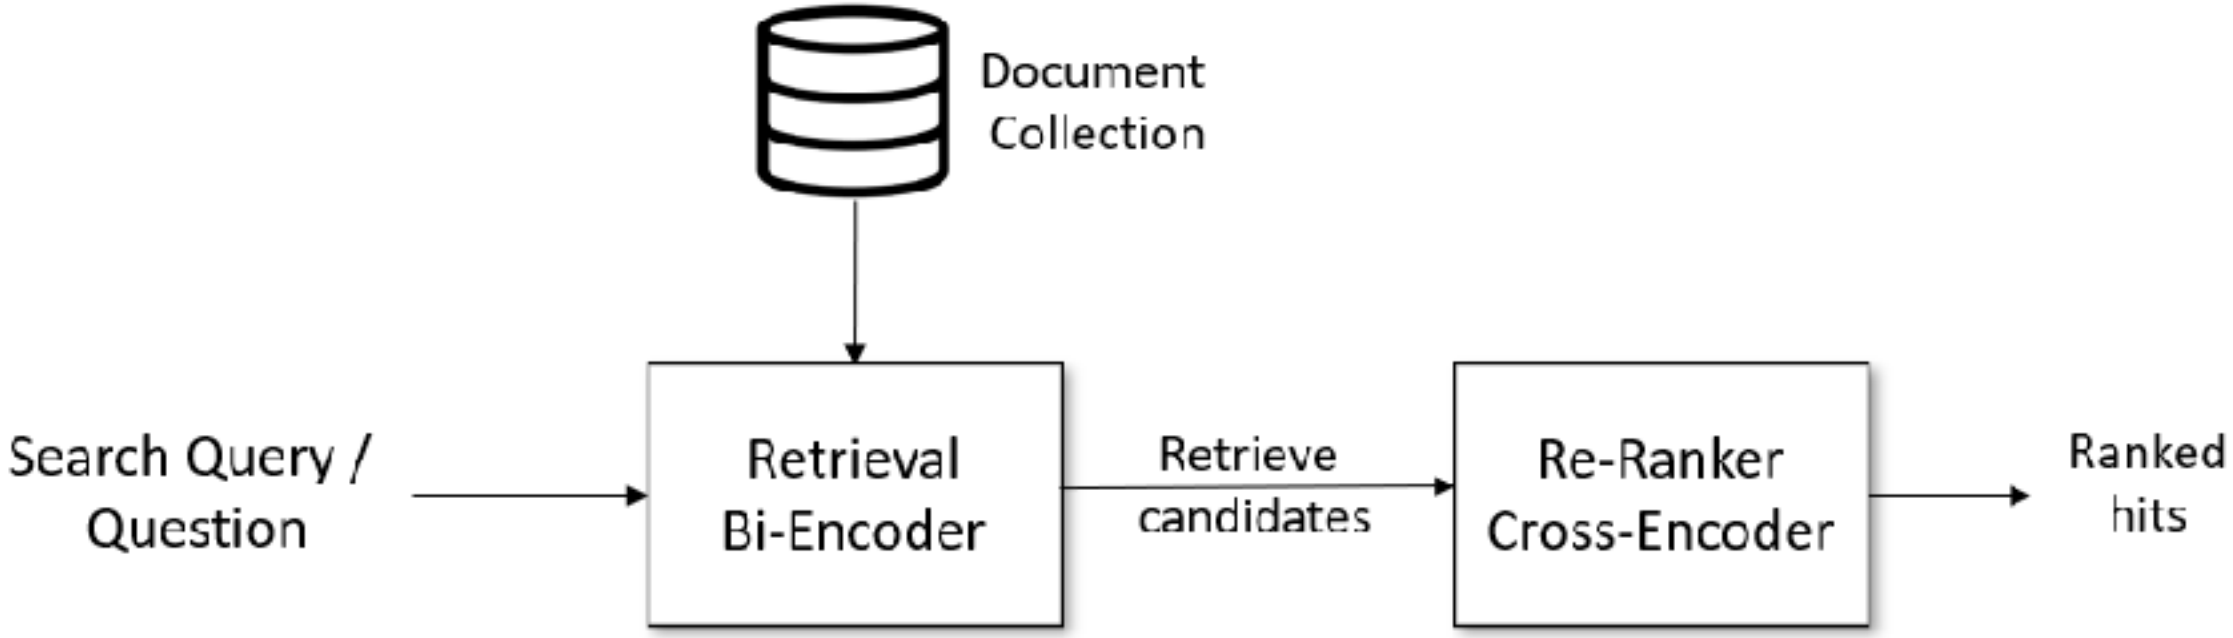
Извлекаем текст и структуру документов

Делим материал на осмысленные фрагменты

Сохраняем источник, версию и права доступа

Строим лексический и/или векторный индекс

Поиск и reranking



Лексический поиск полезен для точных терминов

Векторный поиск сопоставляет представления

Гибридный поиск объединяет кандидатов

Контекст и ответ с подтверждениями

В контекст входят вопрос и выбранные фрагменты

Контекст из руководства	Ответ пользователю
USB-C Power Delivery поддерживается	Зарядка через USB-C возможна
Требуется адаптер нужной мощности	Проверьте мощность и стандарт адаптера
О конкретном блоке сведений нет	Совместимость конкретного блока не подтверждена

Ошибки и оценка RAG

Покрытие: есть ли нужные сведения в источниках?

Retrieval: найдены ли релевантные фрагменты?

Generation: корректно ли использован контекст?

Система: устраивают ли качество, время и стоимость?

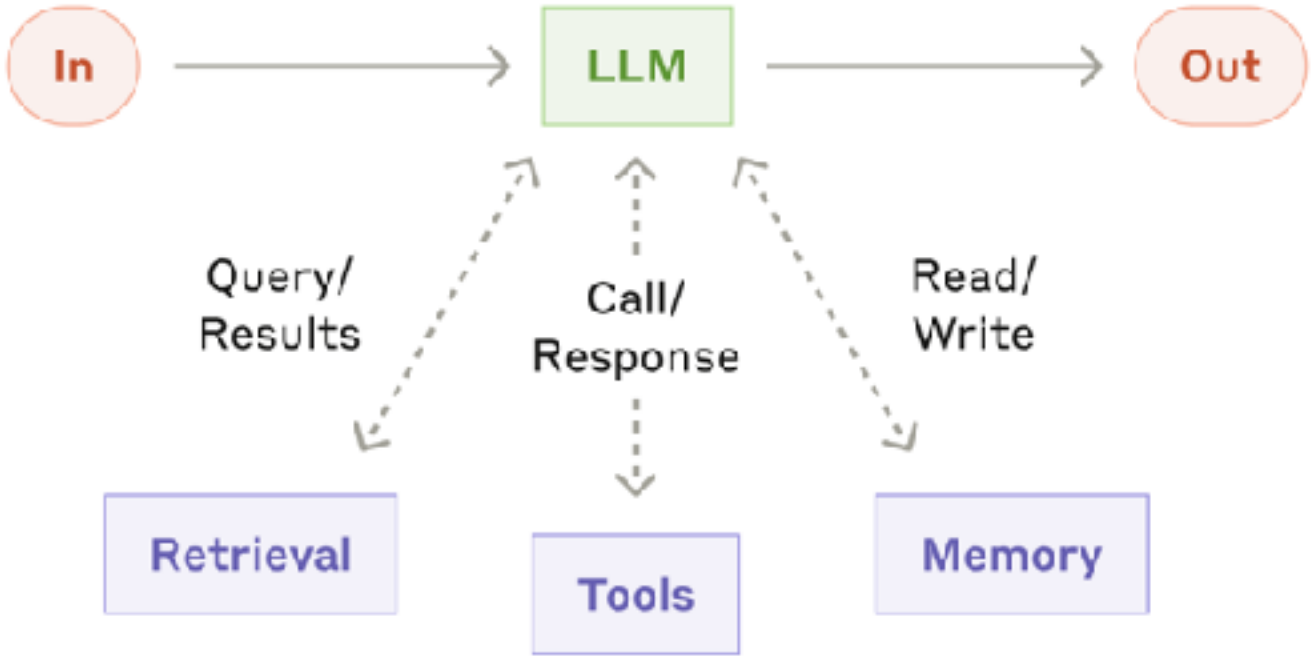
Документ есть в базе, в выдаче его нет, а модель уверенно отвечает. Какой компонент проверим первым?

Помощник по выбору ноутбука

Документация объясняет функции и ограничения

Потребность	Основной механизм
Объяснить ограничение из руководства	RAG
Найти товары дешевле бюджета	Запрос к каталогу
Устойчиво соблюдать формат консультации	Промпт, валидация, при необходимости SFT

Tool calling



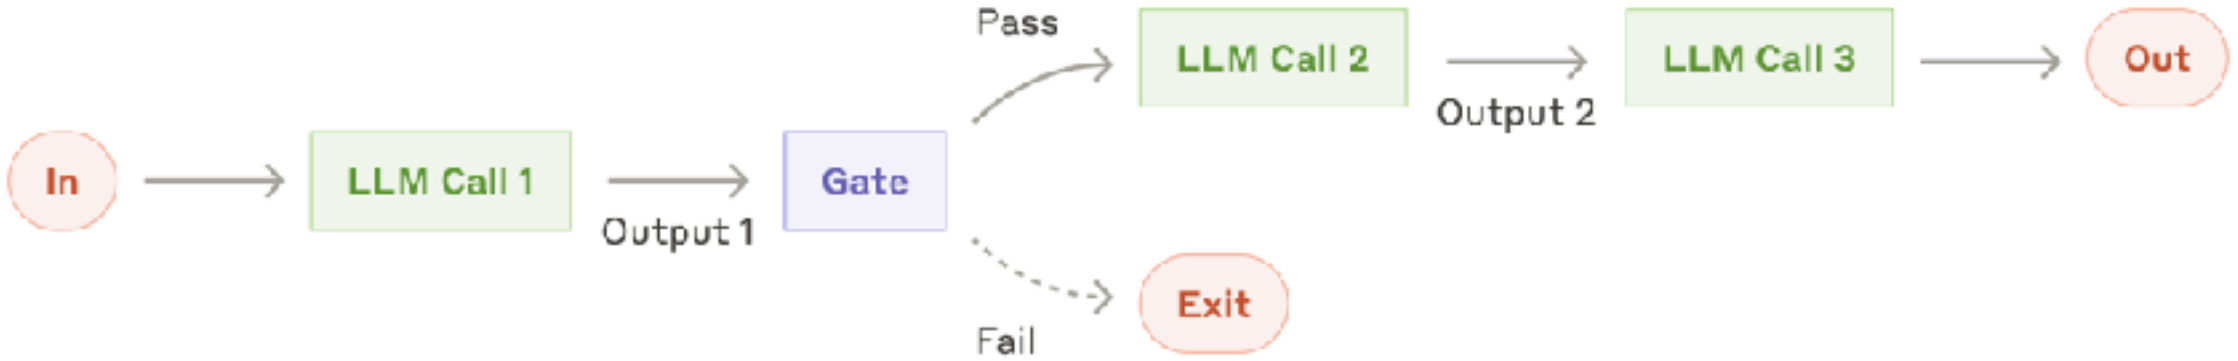
Модель получает описание функции и схему аргументов

Формирует структурированный запрос на вызов

Приложение проверяет и выполняет функцию

Результат возвращается в контекст модели

Workflow и агент

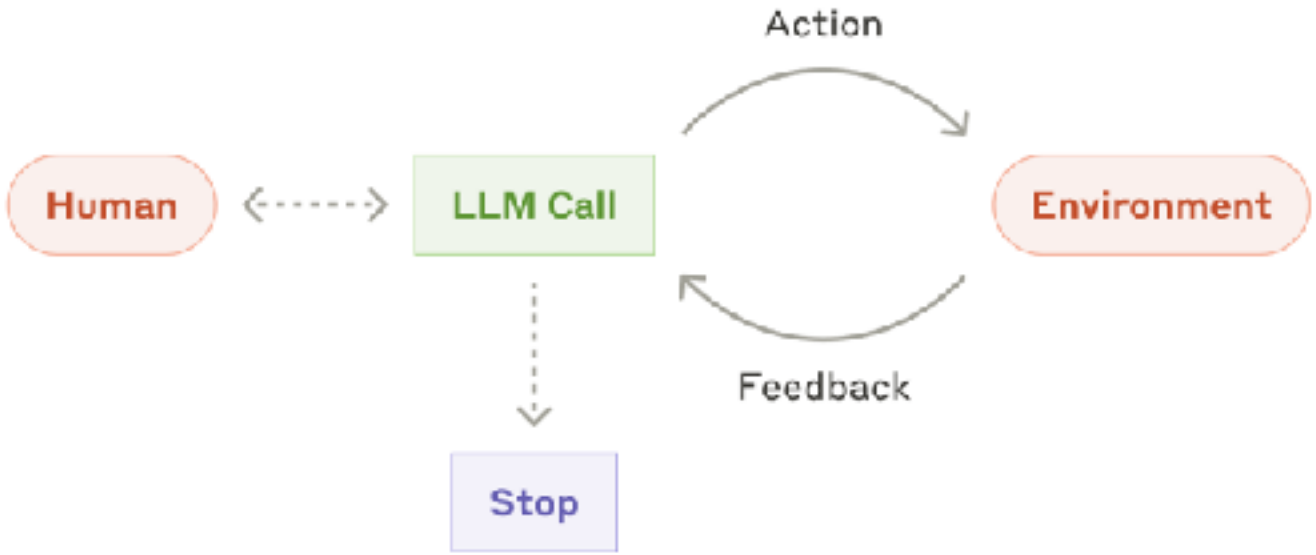


Workflow следует заданной разработчиком логике

Агент выбирает дальнейшие действия по результатам

Степень самостоятельности задаётся архитектурой системы

Агентный цикл



Цель и текущее состояние определяют следующий шаг

Действие даёт наблюдение из внешней среды

После наблюдения выбирается продолжение или завершение

Лимиты ограничивают число шагов и бюджет

Надёжность агентной системы

Проверка аргументов и ограниченные права

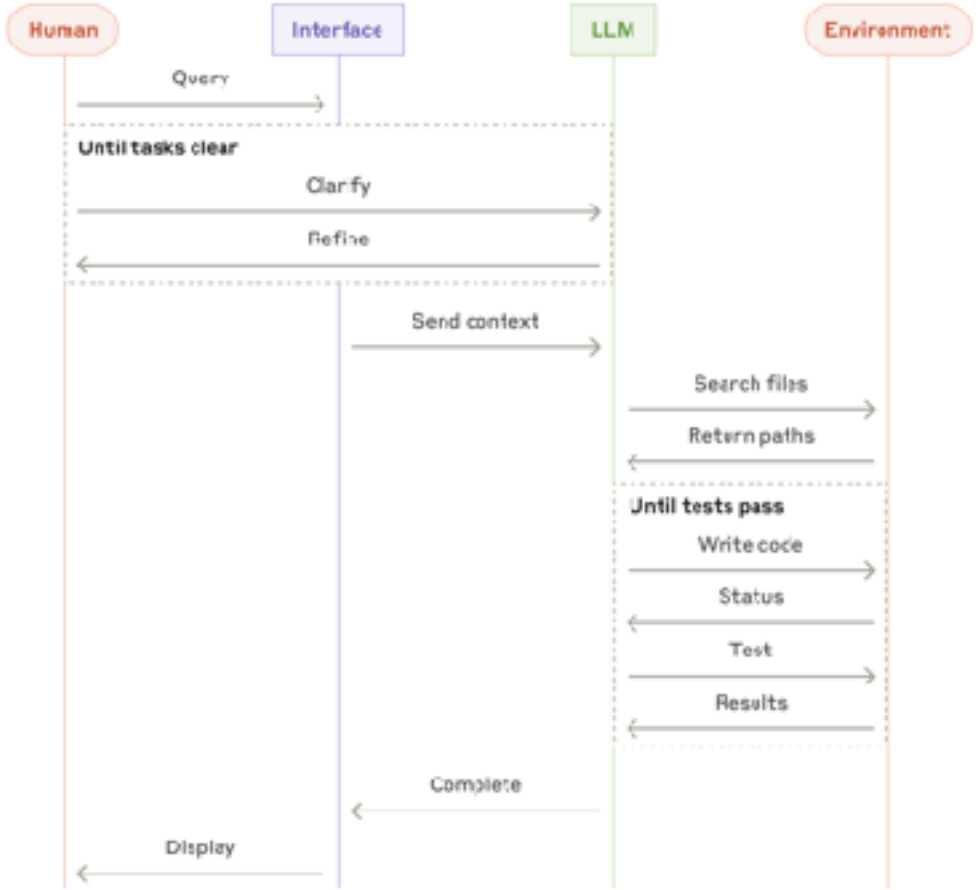
Обработка ошибок, повторов и таймаутов

Лимиты шагов, времени и стоимости

Внешний текст не получает полномочия инструкций

Инструмент оформления действия вернул timeout. Безопасно ли просто вызвать его ещё раз?

Оценка агентов



Главная метрика: выполнена ли задача

Проверяем действия и реальное состояние системы

Измеряем стоимость, задержку и число шагов

Сравниваем с простым workflow на тех же сценариях

Какой компонент решает проблему

Проблема	Что проверяем
Нарушение формата	Промпт, схема, декодирование, SFT
Нет новых фактов	Внешний источник и retrieval
Зависимые действия	Workflow или агентный цикл

Обсуждение: что менять в каждой ситуации и почему?